

FinSight

Hệ thống Phân tích Báo cáo Tài chính Đa năm bằng AI Agent

Bản đặc tả kế hoạch dự án — Tiếng Việt

Một câu mô tả. FinSight nhận Báo cáo tài chính (BCTC) của một doanh nghiệp qua nhiều năm (PDF hoặc bản scan tiếng Việt), **OCR giữ nguyên cấu trúc** → **trích xuất toàn bộ thông tin** → dựng **đồ thị tri thức nối các năm (GraphRAG)** → dùng **AgentRAG** (agent, tool-calling, memory) để tự phân tích, đối chiếu chéo và trả lời các nhiệm vụ cụ thể, có trích dẫn. Con người có thẩm quyền duyệt; phản hồi của họ quay lại tinh chỉnh mô hình.

Contents

1	Tổng quan dự án	1
1.1	Mục tiêu	1
1.2	Luồng hoạt động cốt lõi	1
1.3	Giá trị cho doanh nghiệp (ngân hàng / fintech)	1
1.4	Phạm vi giai đoạn đầu (MVP)	2
2	Kiến trúc tổng thể	2
3	Tech stack	2
4	Đặc tả chi tiết từng pha	3
4.1	Pha 0 — Khởi tạo & Thu thập dữ liệu	3
4.2	Pha 1 — OCR giữ nguyên cấu trúc	3
4.3	Pha 2 — Trích xuất toàn bộ thông tin & Chuẩn hóa	4
4.4	Pha 3 — Đồ thị tri thức đa năm (GraphRAG)	4
4.5	Pha 4 — Phân tích tự động & Đối chiếu (push)	5
4.6	Pha 5 — AgentRAG: Agent, Tool-calling, Memory	5
4.7	Pha 6 — Human-in-the-loop & Vòng tinh chỉnh	6
4.8	Pha 7 — Hiệu năng & Xử lý song song nhiều file	6
4.9	Pha 8 — Đánh giá & Backtest	6
4.10	Pha 9 — Quan sát, Bảo mật, Triển khai	6
5	Bổ sung những phần còn thiếu (so với mô tả ban đầu)	7
6	Cấu trúc thư mục repo đề xuất	7
7	Lộ trình thời gian (gợi ý 12 tuần)	7
8	Tiêu chí thành công	8
9	Rủi ro & Giảm thiểu	8

1 Tổng quan dự án

1.1 Mục tiêu

Xây dựng một hệ thống *tự động phân tích* BCTC tiếng Việt: thay vì một con chatbot hỏi–đáp thụ động, hệ thống **chủ động sinh ra bản phân tích** ngay khi nạp dữ liệu, sau đó cho phép người có thẩm quyền đào sâu bằng hỏi–đáp và phê duyệt kết quả.

1.2 Luồng hoạt động cốt lõi

```

BCTC nhiều năm (PDF/scan)
|
[1] OCR giữ cấu trúc -> document model có cấu trúc
|
[2] Trích xuất + chuẩn hóa -> số liệu tài chính chuẩn (TT200)
|
[3] GraphRAG -> đo thị tri thức nội các năm với nhau
|
[4] PHÂN TÍCH TỰ ĐỘNG (push) -> tỷ số, Altman Z, Beneish M, reconcile
|
[5] AgentRAG (agent + tool + memory) -> nhiệm vụ cụ thể, verify, cite
|
[6] Người có thẩm quyền DUYỆT / sửa (HITL)
|
[7] Feedback -> finetune (model giỏi lên)

```

Phân biệt quan trọng. Trích xuất và phân tích KHÔNG phải RAG: trích xuất là OCR + mô hình bảng; phân tích là công thức tài chính + ML trên số đã trích. **RAG/GraphRAG** chỉ phục vụ bước *nối dữ liệu xuyên năm, kiểm chứng với quy định và hỏi–đáp*.

1.3 Giá trị cho doanh nghiệp (ngân hàng / fintech)

- Rút ngắn thời gian thẩm định 1 bộ BCTC từ vài giờ xuống vài phút, chuẩn hóa.
- Giám sát liên tục theo thời gian, cảnh báo sớm khi tình hình xấu đi.
- Phát hiện dấu hiệu xào nấu sổ sách (Beneish M-Score, lệch lợi nhuận – dòng tiền) trước khi cho vay.
- Mọi kết luận đều có **trích dẫn nguồn** → đáp ứng yêu cầu kiểm toán / tuân thủ.

1.4 Phạm vi giai đoạn đầu (MVP)


- Một công ty niêm yết, BCTC năm, 5 năm gần nhất, bản hợp nhất.
- Gồm: Bảng cân đối kế toán, Báo cáo KQKD, Báo cáo lưu chuyển tiền tệ, Thuyết minh.
- Toàn bộ tiếng Việt.
- BCTC quý sẽ bổ sung ở pha sau (mở khóa đối chiếu quý–năm và cảnh báo sớm theo tốc độ).

2 Kiến trúc tổng thể

```

+----- INGEST SONG SONG (1 lần, bất đồng bộ) -----+
PDF/scan | [P1] OCR -> [P2] Trích xuất -> [P2] Chuẩn hóa (TT200) |
nhiều file| (Paddle/ (TableTransformer/ (canonical chart of accounts) |

```



3 Tech stack

Tầng	Công nghệ đề xuất	Lý do
API / điều phối	FastAPI + Celery + Redis (hoặc Prefect/Temporal)	Bất đồng bộ, xử lý song song nhiều file
Đọc PDF	PyMuPDF; phát hiện text-layer vs scan	Tách đường nhanh: bỏ qua OCR khi có text-layer
OCR tiếng Việt	VietOCR / PaddleOCR (PP-Structure)	OCR có dấu + phân tích bố cục + bảng
Trích xuất bảng (DL)	Table Transformer (TATR) hoặc Donut/Qwen2-VL, finetune LoRA	Bảng đa tầng, ô gộp — phần học sâu lỗi
Chuẩn hóa	Mapping → mã số chỉ tiêu TT200	Để đối chiếu & tính tỷ số nhất quán
Đồ thị tri thức	Neo4j (hoặc networkx + Postgres) + GraphRAG	“Nối các năm” = duyệt đồ thị đa bước
RAG	Qdrant/pgvector + embedding bge-m3 + reranker	Truy hồi quy định, ngữ cảnh xuyên file
Agent	LangGraph	Luồng tường minh, có thể kiểm toán
LLM	API (Claude) cho điều phối + SLM finetune (distill) cho việc rẻ	Cân đối chi phí/tốc độ
Bất định	MAPIE / conformal prediction	Cam kết độ phủ + biết “không chắc”
Lưu trữ	Postgres(+pgvector), MinIO/S3 (file), Redis (cache)	Chuẩn production
Serving	vLLM cho SLM	Suy luận theo lô, nhanh

Tầng	Công nghệ đề xuất	Lý do
Quan sát	Langfuse (trace LLM) + Prometheus/Grafana	Đo độ trễ/chi phí, gỡ lỗi agent
HITL UI	Streamlit → Next.js	Sửa trường, duyệt cờ đỏ

4 Đặc tả chi tiết từng pha

Mỗi pha mô tả theo khung: *Mục tiêu* — *Đầu vào* — *Các bước/Thành phần* — *Công nghệ* — *Đầu ra* — *Tiêu chí hoàn thành (DoD)* — *Rủi ro*.

4.1 Pha 0 — Khởi tạo & Thu thập dữ liệu

- **Mục tiêu:** dựng khung repo, hạ tầng dev, và bộ dữ liệu khởi đầu.
- **Các bước:**
 1. Tải 5 BCTC năm (gồm cả bản text-layer và bản scan) của 1 công ty niêm yết từ cafef.vn / vietstock.vn / hsx.vn.
 2. Tải văn bản chuẩn: Thông tư 200/2014/TT-BTC (chế độ kế toán), TT96/2020 (công bố thông tin) từ vbpl.vn.
 3. Khởi tạo repo, môi trường (Python 3.11, Poetry/uv), `docker-compose` (Postgres, Redis, MinIO, Qdrant).
 4. Thiết lập CI cơ bản (lint, test, pre-commit).
- **Đầu ra:** repo chạy được, dữ liệu thô trong `data/raw/`.
- **DoD:** `docker-compose` up dựng đủ dịch vụ; 5 PDF tải về; sơ đồ schema DB phác thảo.
- **Rủi ro:** bản scan chất lượng kém → chuẩn bị thêm 1–2 công ty dự phòng.

4.2 Pha 1 — OCR giữ nguyên cấu trúc

- **Mục tiêu:** biến PDF/scan thành *document model có cấu trúc*, không mất bố cục bảng.
- **Đầu vào:** PDF (text-layer hoặc ảnh scan).
- **Các bước/Thành phần:**
 1. Phát hiện loại trang: có text-layer → đọc trực tiếp; là ảnh → đưa qua OCR.
 2. Phân tích bố cục (layout analysis): nhận diện vùng bảng, đoạn văn, tiêu đề, header/footer, số trang.
 3. OCR tiếng Việt cho vùng text + ô bảng (giữ tọa độ bounding box).
 4. Tái dựng cấu trúc: bảng → lưới ô (hàng/cột, ô gộp); văn bản → thứ tự đọc đúng.
- **Công nghệ:** PyMuPDF; PaddleOCR PP-Structure (layout + table) ; VietOCR (có thể fine-tune cho phong chữ BCTC).
- **Đầu ra:** JSON document model: `{pages:[{blocks, tables:[{cells, bbox}], reading_order}]}`.
- **Đánh giá:** CER/WER cho text; TEDS (Tree-Edit-Distance Similarity) cho cấu trúc bảng.
- **DoD:** 1 BCTC scan → JSON cấu trúc đầy đủ, bảng cân đối tái dựng đúng $\geq 95\%$ ô.
- **Rủi ro:** ô gộp/đa tầng header → cần finetune + hậu xử lý theo luật.

4.3 Pha 2 — Trích xuất toàn bộ thông tin & Chuẩn hóa

- **Mục tiêu:** từ document model → số liệu tài chính có cấu trúc, chuẩn hóa (BCTC rất dài).
- **Các bước:**
 1. Nhận dạng cấu trúc bảng (table structure recognition) cho 4 báo cáo chính + các bảng trong thuyết minh.
 2. Trích metadata: kỳ báo cáo, đơn vị tiền (nghìn/triệu đồng), tên công ty, mã số thuế, trạng thái kiểm toán.
 3. Parse số: dấu phân tách nghìn kiểu VN, số âm trong ngoặc (1.234), ô trống.
 4. **Chuẩn hóa:** ánh xạ mỗi dòng → **mã số chỉ tiêu TT200** (ví dụ “Tiền và tương đương tiền” → mã 110). Đây là cầu nối cho phân tích & đối chiếu.
- **Công nghệ:** Table Transformer / Donut + **LoRA finetune** trên bảng BCTC tiếng Việt; rule-based normalizer.
- **Đầu ra:** bảng số liệu chuẩn hóa theo năm trong Postgres (schema canonical).
- **Schema 1 dòng (ví dụ):**

```
{ "chi_tieu": "Tien va tuong duong tien", "ma_so": "110",
  "thuyet_minh": "V.01", "nam": 2024,
  "gia_tri": 12345678901, "don_vi": "VND" }
```

- **Đánh giá:** độ chính xác theo ô (đặc biệt ô số), độ chính xác ánh xạ dòng → mã số.
- **DoD:** 5 năm → bảng chuẩn hóa đầy đủ; golden set ~15–20 bảng để đo.
- **Rủi ro:** tên chỉ tiêu khác nhau giữa các năm/công ty → cần từ điển đồng nghĩa + fuzzy match.

4.4 Pha 3 — Đồ thị tri thức đa năm (GraphRAG)

- **Mục tiêu:** “nối các năm với nhau” để truy vấn đa bước, đối chiếu xuyên file.
- **Thiết kế đồ thị:**
 - **Node:** chỉ tiêu (mã số), giá trị theo năm, công ty, mục thuyết minh, kỳ báo cáo.
 - **Edge:** thuộc năm, thuộc báo cáo, tham chiếu thuyết minh, quan hệ năm-quá-năm, quan hệ tính toán (ví dụ Lợi nhuận gộp = Doanh thu – Giá vốn).
- **GraphRAG indexing:** trích entity + quan hệ, sinh tóm tắt cụm (community summary) để trả lời câu hỏi “toàn cục”.
- **Công nghệ:** Neo4j (hoặc networkx + Postgres); GraphRAG (Microsoft hoặc tự xây); embedding bge-m3 cho truy hồi.
- **Đầu ra:** đồ thị truy vấn được; API `query_graph()` trả dữ liệu xuyên năm.
- **DoD:** truy vấn “doanh thu 2020–2024” và “đường tính lợi nhuận gộp năm 2023” chạy đúng.
- **Rủi ro:** bùng nổ node → chỉ mô hình hóa chỉ tiêu cốt lõi + thuyết minh quan trọng.

4.5 Pha 4 — Phân tích tự động & Đối chiếu (push)

- **Mục tiêu:** ngay khi có dữ liệu, *chủ động* sinh bản phân tích, không chờ hỏi.
- **Tính toán:**

- **Tỷ số & xu hướng:** thanh khoản (current, quick), đòn bẩy (D/E, Nợ/EBITDA), sinh lời (ROA, ROE, biên LN), khả năng trả lãi (interest coverage), vòng quay vốn (DSO/DIO/DPO).
- **Dự báo phá sản:** Altman Z” (cho doanh nghiệp dùng giá trị sổ sách).
- **Phát hiện xào nấu:** Beneish M-Score (8 biến, cần 2 năm liên tiếp); accruals; lệch lợi nhuận – dòng tiền; Benford.
- **Đối chiếu (reconciliation):** thuyết minh vs sổ trên báo cáo; nhất quán năm-quá-năm; (sau: lũy kế quý vs năm).
- **Bất định:** dùng conformal prediction để *abstain* (“không đủ cơ sở”) thay vì đoán bừa.
- **Đầu ra: Bản phân tích / Thẻ rủi ro** có cờ đỏ + trích dẫn vị trí số liệu.
- **DoD:** sinh thẻ phân tích tự động cho 1 công ty 5 năm, mỗi cờ đỏ truy được về dòng nguồn.
- **Rủi ro:** công thức sai do đơn vị/dấu → unit test cho từng chỉ số.

4.6 Pha 5 — AgentRAG: Agent, Tool-calling, Memory

- **Mục tiêu:** cho phép giao *nhiệm vụ cụ thể* bằng ngôn ngữ tự nhiên trên nền dữ liệu đã phân tích.
- **Các loại nhiệm vụ (theo đúng mô tả):**
 - “Trích xuất toàn bộ thông tin BCTC năm 2023.”
 - “Phần nào khớp / phần nào lệch qua các năm?” (nhiệm vụ đối chiếu).
 - “So sánh khoản mục *hàng tồn kho* giữa 2020–2024.”
 - “Tính và giải thích biến động biên lợi nhuận gộp 5 năm.”
- **Tools (function calling):** `query_graph`, `get_lineitem`, `compute_ratio`, `reconcile`, `search_regulation` (RAG vbpl/TT200), `web_search`.
- **Memory:**
 - Ngắn hạn: ngữ cảnh hội thoại hiện tại.
 - Dài hạn: phát hiện đã được duyệt, lưu theo *session = một hồ sơ doanh nghiệp*.
- **Verify khi nghi ngờ:** confidence thấp / nghi vi phạm → truy hồi quy định + (nếu cần) web search nguồn chính thống → **trích dẫn**; *abstain* khi không đủ bằng chứng.
- **Công nghệ:** LangGraph (đồ thị quyết định tường minh, audit được).
- **Đầu ra:** câu trả lời/nhiệm vụ hoàn thành kèm trích dẫn + đường suy luận lưu lại.
- **DoD:** agent hoàn thành đúng 4 loại nhiệm vụ mẫu, mỗi kết quả có trích dẫn.
- **Rủi ro:** ảo giác số liệu → *bắt buộc* agent chỉ lấy số qua tool, không tự “nhớ” số.

4.7 Pha 6 — Human-in-the-loop & Vòng tinh chỉnh

- **Mục tiêu:** người có thẩm quyền duyệt bản phân tích; phản hồi thành dữ liệu huấn luyện.
- **Các bước:**
 1. UI duyệt/sửa trường trích xuất & cờ đỏ (Streamlit).
 2. Active learning: ưu tiên đưa case confidence thấp cho người xem.
 3. GOM correction → LoRA finetune lại extractor; **trigger theo drift** (độ phủ conformal tụt / PSI), không theo lịch cứng.
- **Đầu ra:** mỗi vòng feedback cải thiện độ chính xác đo được.

- **DoD:** chạy trọn 1 vòng: sửa → finetune → accuracy tăng có số liệu.
- **Rủi ro:** dữ liệu correction ít → gộp với dữ liệu tổng hợp (synthetic) để đủ tín hiệu.

4.8 Pha 7 — Hiệu năng & Xử lý song song nhiều file

- **Nguyên tắc:** làm nặng *một lần* lúc nạp; truy vấn chỉ duyệt thứ đã dựng sẵn.
- **Song song 3 mức:** theo file (mỗi file 1 task Celery), theo trang (OCR song song), theo lô GPU (gộp lời gọi mô hình).
- **Pipeline không rào chắn:** file nào xong xử lý tiếp file đó (wall-clock = file chậm nhất).
- **Cache:** hash file (idempotency), cache embedding, **semantic cache** cho câu hỏi lặp.
- **Serving:** vLLM cho SLM; *fast-path* bằng SLM rẻ, chỉ escalate model lớn khi confidence thấp.
- **DoD:** xử lý N file song song; báo cáo throughput (file/phút) + p95 latency truy vấn.
- **Rủi ro:** nghẽn GPU → hàng đợi + backpressure.

4.9 Pha 8 — Đánh giá & Backtest

- **Metrics theo tầng:** OCR (CER/WER), bảng (TEDS), trích xuất (cell accuracy), ánh xạ mã số (accuracy), đối chiếu (tỷ lệ bắt lỗi trên bộ synthetic cấy lỗi), rủi ro (backtest).
- **Backtest giá trị thật:** chạy Altman Z / Beneish M trên công ty đã *hủy niêm yết / scandal kế toán* → chứng minh hệ thống flag được *trước* sự kiện.
- **DoD:** báo cáo đánh giá đầy đủ + ít nhất 1 ca backtest thành công.

4.10 Pha 9 — Quan sát, Bảo mật, Triển khai

- **Quan sát:** Langfuse (trace agent/LLM, chi phí token), Prometheus + Grafana (hệ thống).
- **Bảo mật & tuân thủ:** không dùng dữ liệu PII thật; audit log mọi kết luận; phân quyền người duyệt.
- **Session/Memory store:** mỗi hồ sơ là một phiên có thể mở lại, kèm lịch sử phát hiện & phê duyệt.
- **Triển khai:** docker-compose cho dev; tách service (ingest, agent, UI).
- **DoD:** chạy end-to-end có giám sát, mở lại được session cũ.

5 Bổ sung những phần còn thiếu (so với mô tả ban đầu)

Mô tả gốc tập trung OCR → trích xuất → AgentRAG. Để thành một dự án “thật sự hữu ích” và *bảo vệ được trước người chấm chốt khe*, cần bổ sung:

Hạng mục bổ sung	Vì sao cần
Chuẩn hóa TT200	Cầu nối để phân tích & đối chiếu nhất quán; thiếu nó thì số liệu rời rạc.
Tầng phân tích rủi ro	Biến số thô thành <i>tín hiệu ra quyết định</i> (Altman, Beneish) — đây mới là giá trị.
Bộ đánh giá (eval harness)	Không đo được thì không chứng minh được “hữu ích”.
HITL + vòng finetune	Biến phản hồi người dùng thành cải thiện model (flywheel).
Conformal / abstention	Cam kết độ tin cậy; biết “không chắc” thay vì bịa.

Hạng mục bổ sung	Vì sao cần
Drift detection	Trigger huấn luyện lại đúng lúc (MLOps thật, không phải cron).
Quan sát (observability)	Gỡ lỗi agent, theo dõi chi phí/độ trễ.
Bảo mật / PII	Dữ liệu tài chính nhạy cảm; bắt buộc với ngành.
Hiệu năng / song song	Yêu cầu thực tế khi xử lý nhiều file.
Data & model versioning	Tải lập kết quả (DVC / MLflow).
Kiểm thử (testing)	Unit test cho công thức tài chính, integration test pipeline.

6 Cấu trúc thư mục repo đề xuất

```
finsight/
  data/                # raw/ , processed/ , golden/ , synthetic/
  configs/             # cấu hình model, pipeline, prompt
  finsight/
    ingest/            # P1: doc PDF, phát hiện scan, hàng đợi
    ocr/               # P1: OCR + layout (Paddle/VietOCR)
    extraction/        # P2: table model + LoRA + normalizer TT200
    graph/             # P3: dùng GraphRAG, query do thi
    analysis/          # P4: tỷ số, Altman, Beneish, reconcile
    agent/             # P5: LangGraph, tools, memory
    rag/               # RAG quy định (vbpl), embedding, reranker
    hitl/              # P6: review UI + thu thập correction
    serving/           # P7: vLLM, cache, API
    eval/              # P8: metrics, backtest, golden set
    common/            # schema, db, logging, config
  ui/                  # Streamlit / Next.js
  docker/              # docker-compose, Dockerfile
  tests/
  notebooks/
  README.md
```

7 Lộ trình thời gian (gợi ý 12 tuần)

Tuần	Công việc	Kết quả
1	Pha 0: data + repo + hạ tầng	Khung chạy
2–3	Pha 1–2: OCR + trích xuất text-layer + chuẩn hóa TT200	MVP trích xuất, golden set
4	Pha 4: tầng phân tích (tỷ số + Altman + Beneish)	Đã có giá trị thật
5–6	Pha 1: OCR scan + Pha 6: LoRA finetune từ correction	Học sâu + flywheel
7–8	Pha 3: GraphRAG + Pha 4: đối chiếu xuyên năm	Liên thông các năm
9–10	Pha 5: AgentRAG (tool + memory) + RAG quy định + conformal	Agent + tuân thủ

Tuần	Công việc	Kết quả
11–12	Pha 7–9: song song, quan sát, backtest, viết blog/README	Demo + bằng chứng

Quy tắc thực thi. Làm *lát cắt đọc* trước (trích xuất → thử rủi ro chạy được ở tuần 4), rồi mới đào sâu từng tầng. *Không* dừng hết hạ tầng rồi mới có cái chạy.

8 Tiêu chí thành công

- Trích xuất: cell accuracy $\geq 95\%$ trên golden set; ánh xạ mã số $\geq 90\%$.
- Đối chiếu: bắt $\geq 90\%$ lỗi cây trên bộ synthetic có ground-truth.
- Phân tích: backtest Altman/Beneish flag đúng ≥ 1 ca công ty đã vỡ/scandal.
- Agent: hoàn thành 4 loại nhiệm vụ mẫu, 100% kết luận số liệu có trích dẫn (không bịa số).
- Hiệu năng: xử lý song song, có số liệu throughput & p95 latency.

9 Rủi ro & Giảm thiểu

Rủi ro	Giảm thiểu
Bản scan kém, bảng phức tạp	Finetune OCR + hậu xử lý theo luật; chọn công ty BCTC sạch trước.
Ảo giác số liệu của LLM	Agent chỉ lấy số qua tool; cấm “nhớ” số; trích dẫn bắt buộc.
Thiếu dữ liệu correction để finetune	Bổ sung dữ liệu tổng hợp có ground-truth điều khiển được.
Over-claim novelty	Pitch bằng cam kết/độ đo (coverage, accuracy), không bằng tính từ.
Scope phình to	Khóa MVP: 1 công ty, BCTC năm, 5 năm; tính năng khác để pha sau.

— Hết bản kế hoạch FinSight —